

AI Architecture

Provider-Bağımsız AI Gateway, Orkestrasyon, Evals ve Human Oversight

APPROVED BASELINE

Versiyon 1.1.0 • 27 Temmuz 2026

Kural ne diyor, vicdan ne söylüyor?

BELGE KONTROLÜ

Alan	Değer
Belge kimliği	KEFE-AIA-001
Sürüm	1.1.0
Tarih	27 Temmuz 2026
Durum	Approved Baseline
Belge sahibi	AI / Engineering
Normatif otorite	KEFE-MPD v1.2.0 + KEFE-ENG v0.4.0
Gözden geçirme ritmi	Her ana karar veya ilgili sistem değişikliği sonrası
Çelişki kuralı	En yeni onaylı KEFE Master Product Document kararı geçerlidir; belge manifesti ve durumlar için KEFE-GOV geçerlidir.

1. Mimari ilke

KEFE domain'i hiçbir model sağlayıcısının SDK'sına bağlanmaz. AI kabiliyetleri task port'ları üzerinden çağrılır; provider/model seçimi orkestrasyon ve konfigürasyon katmanında çözülür.

2. Katmanlar

Katman	Sorumluluk
AI Capability Port	neutral_summary, claim_classification, question_proposal, clustering, moderation_assist, localization, recommendation vb.
AI Orchestrator	task policy, routing, retries, fallback, human gate
Provider Adapters	OpenAI/Gemini/Anthropic/local vb. SDK izolasyonu
Model Registry	provider, model, version, capability, cost/latency metadata
Prompt Registry	template id/version, locale, risk class
Evaluation Layer	offline/online quality, safety, drift, golden set
Audit Store	input/output hash, review state, model/prompt lineage

3. Routing policy

- Provider seçimi kalite + latency + cost + availability + language + data residency + risk gereksinimlerine göre yapılabilir.
- Routing typed/versioned config'tir; domain logic provider adı bilmez.
- High-risk task'ta ensemble/second-pass/human review policy uygulanabilir.

4. Capability matrisi

Capability	Girdi	Çıktı	Human gate
Neutral summary	sources + claims	draft summary	TODAY/high-risk zorunlu
Claim classification	claim + evidence	status proposal	zorunlu editorial approval
Question proposal	Issue schema	question draft	publish öncesi
Reason clustering	moderated reasons	clusters + summaries	sampling QA
Moderation assist	UGC	risk labels	high-risk human
Localization	canonical content + country context	localized draft	high-risk country editor
Recommendation	candidate set + safe signals	ranked ids	policy guardrails
Insight language	aggregate metrics	consumer sentence	methodology guardrails

5. Model/Prompt kayıt sözleşmesi

Alan	Kural
model_provider/name/version	Her çağrıda çözülür ve loglanır.
prompt_template_id/version	Hard-coded prompt yerine registry.
input_hash/output_hash	Reproducibility + cache; raw PII loglanmaz.
confidence	Provider skoru tek başına truth değildir.
cost/latency	FinOps + routing.
review_state/reviewer	Human oversight.
safety_labels/fallback_path	Audit ve incident analysis.

6. Cache ve determinism

- Tekrarlanabilir editorial task'lar input_hash + prompt/model/version + locale üzerinden cache edilebilir.
- Research'te determinism parametreleri/seed varsa saklanır; sağlayıcı desteklemiyorsa bu açıkça kaydedilir.
- UGC moderation gibi dynamic task'larda stale cache kullanılmaz.

7. Resilience

- Timeout + bounded retry + exponential backoff/jitter + circuit breaker.
- Fallback provider veya degraded path tanımlı.
- AI unavailable olduğunda Case → Weigh → Commit → Reveal core loop mümkün olduğunca çalışmaya devam eder.
- Kill switch capability/provider/model seviyesinde bulunur.

8. Veri ve güvenlik

- Minimum necessary context gönderilir; Identity Vault PII AI sağlayıcısına gönderilmez.
- Provider data retention/training seçenekleri release/vendor review sırasında doğrulanır.
- Prompt injection ve malicious URL/content untrusted input olarak ele alınır; tool access allowlist ve sandbox uygulanır.
- Secret ve provider credentials secret manager'dadır.

9. AI eval standardı

Eval	Örnek ölçüm
Neutrality	blind editorial rubric / bias markers
Factual grounding	claim/source support precision
Safety	high-risk false negative/positive
Localization	meaning preservation + jurisdiction correctness
Question quality	leadingness, clarity, answerability
Clustering	semantic cohesion + duplicate reduction
Cost/latency	task-level budget
Human override	reviewer disagreement rate

10. AI'nın yapamayacağı işler

- Suçluluk/masumiyet hükmü
- Bilimsel/hukuki gerçeği oyla belirleme

- Uzman görüşü uydurma
- AI görüşünü kullanıcı görüşü gibi sunma
- High-risk gerçek olayı tek başına publish etme
- Kalıcı siyasi/kişilik kimliği tahmin etme

Bağlayıcı gereksinimler

ID	Gereksinim	Üst kaynak
AIA-001	Domain hiçbir provider SDK'sına doğrudan bağımlı olamaz.	MPD architecture principles
AIA-002	Her önemli AI çıktısı model/prompt version ve review state ile kaydedilir.	MPD §41
AIA-003	High-risk publish human gate içerir.	MPD §41
AIA-004	AI unavailable core decision loop'u mümkün olduğunca düşürmez.	MPD resilience principles
AIA-005	Prompt/model config versioned ve audited olmalıdır.	MPD configuration principles

KARARLAR — V1.1.0

Karar 1 — Task/provider routing

Tek bir AI sağlayıcısı “KEFE AI” değildir. Her capability AI Orchestrator üzerinden benchmark, locale, risk, latency, cost ve availability sinyalleriyle route edilir. MVP primary provider seçilebilir fakat fallback adapter contract ve provider exit plan zorunludur.

Karar 2 — Golden eval set

Critical capability başına ilk minimum 200 kuratörlü örnek; desteklenen ana locale başına en az 50 örnek kapsanır. High-risk neutralization/claim/question setleri ayrıca insan reviewer disagreement örnekleri içerir. Set versioned ve büyüyen yapıdır.

Karar 3 — Future AI experiences

Perspective Coach test edilir; AI Devil's Advocate ve Debate/Sparring yalnız açık LAB/EDU bağlamında, AI olduğu görünür şekilde çalışır. Consumer core'da AI insan görüşü gibi davranamaz.

Değişiklik Geçmişi

Sürüm	Tarih	Değişiklik
1.0	27 Temmuz 2026	İlk onaylı baseline oluşturuldu.

Sürüm	Tarih	Değişiklik
1.1.0	27 Temmuz 2026	Provider routing, eval golden set, cache/reproducibility, resilience ve future AI experience sınırları kesinleştirildi.